

第19章 大数据处理系统分析与设计核心知识点

一、考情概览

本章是近年高频考点，且从选择题向**案例分析+论文**全面渗透：

- **2024年上半年**：案例分析直接考 Lambda/Kappa 架构对比与大数据架构图补全（Nginx、HBase、Spark Streaming、Spark、MapReduce、ETL、HDFS、Sqoop、Flume、Kafka 等技术归属判断）；论文题考"论大数据 Lambda 架构"，要求论述批处理层、加速层、服务层三层的特性与用途及项目应用。
- **2025年**：案例分析考企业级数据仓库与 ETL 设计（事实表/维度表、增量抽取、HDFS 设计目标、MapReduce 的 Map/Reduce 阶段任务）以及实时流处理系统设计；实时流处理工具选型（Flink）也是关键考点。
- **2026年上半年**：案例分析考 Lambda 架构各层作用与互补关系、缺点（两套代码维护、全量重算开销大），Kappa 架构下消息队列需支持"数据回放重计算"的特性（如 Kafka、Pulsar），以及 Flink 的 Watermark 乱序处理机制。

二、核心知识点

1. 大数据 4V 特性与架构设计原则（选择题基础）

- **4V**：数据量大（Volume）、类型多样（Variety）、产生与处理速度快（Velocity）、价值高（Value）；结构化/半结构化/非结构化数据划分。
- **六大设计原则**：可扩展（分布式环境+模块化设计）、可管理、数据安全（加密、访问控制、备份恢复、审计日志、持续监控）、高性能（数据分区、分布式计算、并行处理、内存计算）、高可用（数据冗余、自动故障转移如 ZooKeeper/Keepalived、负载均衡如 Haproxy/Nginx/LVS）、稳定性。

2. 架构类型与 Lambda/Kappa 对比（案例+论文必考）

- **批处理架构**：离线、高吞吐、低实时，四模块"采集→存储→处理→输出"，代表 MapReduce/Spark。
- **流处理架构**：连续无界流式处理、低延迟，代表 Flink/Storm，两大组件为数据流和运算符；局限是无法处理历史数据、需考虑并发性与一致性。
- **混合架构**：批+流结合，如 Spark 同时支持批处理与流处理。
- **Lambda 架构**（最成熟最稳定）：批处理层（Hive/Spark SQL/MapReduce，存储不可变、只追加的全量数据，精度高但延迟高）、加速层（Storm/Spark Streaming/Flink，只处理最新数据，弥补高延迟）、服务层（合并两层结果，提供低延迟查询与 Ad-hoc 查询，可用 Kylin/Presto/Impala/Druid）。优点是兼顾准确性与实时性；缺点是需维护两套代码、开发和运维复杂度高。
- **Kappa 架构**：只保留流处理层+在线服务层，一切皆流，通过上游消息重放完成历史重算，流批统一用一套代码；代表 Flink+Kafka。对消息队列的长期存储与重放（Replay）能力要求极高。
- **考试易错点**：实时流通道保障**实时性**，离线批处理通道保障**最终一致性**（不要说反）；需要复杂历史数据修正重跑时，Lambda 的批处理层反而更有优势。

3. IOTA 架构（了解层次）

通用数据模型贯穿始终+边缘计算（Edge SDKs & Edge Servers）+实时数据缓存区（Kudu/HBase）+历史数据沉浸区（HDFS）+Dumper 导入组件+查询引擎（Presto/Impala/ClickHouse）+实时模型反馈；特点是"去 ETL 化"、即时查询、边缘计算。

4. 数据存储与管理

- **数据存储四流程**：采集（离线采集/ETL、实时采集/Kafka 消费者、互联网采集/爬虫）→清洗（5 步流程，占分析过程 50%~80% 时间）→转换（6 步：发现、映射、提取、代码生成、代码执行、审查）→存储。
- **行存储 vs 列存储**：行存储写入效率高、保证完整性（MySQL 适合 OLTP）；列存储读取无冗余、适合大数据计算和 OLAP（HBase 列族平衡两者；ES 默认全字段索引适合全文检索）。
- **元数据管理**：技术元数据与业务元数据；7 种管理方式（数据源、ETL 规则、数据仓库、报表、接口文件格式、商业、其他元数据）。
- **数据关系图谱**：血缘关系 4 特征——归属性、多源性、可追溯性、层次性。
- **数据安全**：数据安全=认证（Kerberos）+授权（RBAC、Sentry/Ranger）；表安全 4 等级 S1~S4；数据产生→存储→使用→传输→展示→销毁全流程安全。

5. 数据处理与分析

- **离线 vs 实时的本质区别**：有界数据用批处理（离线），无界数据用流处理（实时）；口诀"离线算存量，实时算增量"，延迟容忍度高选离线（MapReduce/Spark），要求秒级响应选实时（Flink）。
- 常用离线同步工具：Sqoop、DataX（source→channel→sink 抽象）；离线典型架构 HDFS+MapReduce+Hive。
- 图计算：顶点和边、有向/无向图、伪图/属性图/二分图，Spark GraphX（VertexRDD+EdgeRDD），三类算法（路径搜索、中心性如 PageRank、社群发现）。
- 分析技术：机器学习三分类（监督、非监督、强化）；搜索引擎 Elasticsearch（基于 Lucene、倒排索引、ELK 栈）与 Apache Solr。

三、备考建议

1. **Lambda/Kappa 三层结构、技术选型、优缺点**是绝对核心，须能画出架构图并做技术归属判断（案例题实际考过两次级别）。
2. 案例题趋势越来越"落地化"：会考 Flink Watermark、消息队列重放特性、增量抽取方法、Map/Reduce 阶段职责，复习时结合具体组件特性记忆。
3. 论文方向以"大数据处理架构（Lambda）及其应用"为模板，准备一个同时涉及实时+离线的项目素材（如实时大屏+T+1 报表），并熟悉 4V 特征、三层用途的论述框架。