第24章 AI大模型（LLM）核心知识点

一、真题考情概览

- **2024年至2025年（铺垫期）**：AI 相关内容主要出现在综合知识的选择题中，考查机器学习分类、神经网络基本结构、训练与过拟合等基础概念；案例分析与论文尚未以大模型为独立主题，但智能客服、智能运维、测试用例生成等场景已作为业务背景频繁出现。
- **2025年下半年**：案例分析必答题为需求工程，选答题覆盖结构化分析与设计、缓存数据库、嵌入式、Web 系统设计；论文四题为软件测试、设计模式应用、系统成本效益分析、云计算运维。大模型仍未单独命题，属于背景词。
- **2026年上半年（关键转折）**：论文第一题考“LLM 大模型语言辅助测试”，要求说明 LLM 生成测试用例的具体实现、使用 LLM 的优势与问题及应对措施、其局限性与解决办法；案例分析第五题考“Web 应用与 AI 智能体融合平台”，涉及后端架构选型、负载均衡与中间件。综合知识仍以传统考点为主，AI 占比有限但已稳定出现。
- **命题走向**：从“什么是大模型”转向“大模型怎么落进系统”，题型以概念辨析、链路还原、方案与选型对比为主。LLM 与智能体的分工要分清：LLM 是推理内核，智能体是带规划、工具、记忆的工程外壳（详见第23章）。以下真题均为回忆版，个别表述与官方版本可能有出入。

二、核心知识点总结

1. Transformer 与自注意力（概念题高频）

- 结构：编码器与解码器均由多层堆叠，每层为“多头自注意力 + 前馈网络”，配残差连接与层归一化。
- 自注意力：输入分别映射为 Q、K、V 三组向量，用 Q 与 K 的点积算相关性权重，再对 V 加权求和；点积除以维度的平方根，防止数值过大导致 Softmax 饱和、梯度消失。
- 多头：多组独立参数并行计算后拼接，从不同子空间捕捉语法、指代、语义等关系。
- 位置编码：自注意力本身没有顺序感，必须注入绝对位置（正弦编码）或相对位置（RoPE、ALiBi），否则语序信息丢失，这是“为什么需要位置编码”的标准答法。
- 三种主流结构：纯编码器（BERT，掩码语言模型，擅长理解与分类）、纯解码器（GPT，自回归预测下一 token，擅长生成）、编码解码（T5，适合翻译与摘要）。
- 复杂度：标准注意力时间与显存随序列长度平方增长，这是长上下文成本高的根源，也是 FlashAttention、稀疏注意力、线性注意力的动因。

2. 分词、Token 与上下文窗口

- 分词：把文本切成 token，主流为 BPE、WordPiece 子词切分，兼顾词表规模与未登录词；中文一个汉字通常不足一个 token，英文长词常被切成多个子词。
- token 直接决定计费、上下文长度与生成成本，估算容量时按 token 而非字数。
- 上下文窗口：模型单次可见的 token 上限，输入与输出共享额度，输出另有最大生成长度限制；超限要截断、摘要或分块续写。
- 长上下文三策略：检索式（RAG 按需召回）、压缩式（摘要与信息抽取）、缓存式（KV 缓存复用前缀）。代价一是注意力平方复杂度，二是“中间遗忘”，即长文本中段信息利用率明显下降。

3. 训练三阶段（SFT 与对齐必考辨析）

- 预训练：海量无标注语料做下一 token 预测，得到基座模型，掌握语言规律与世界知识，但不会听指令。
- 指令微调（SFT）：用“指令-回答”配对数据做监督训练，让模型学会按意图与格式作答。
- 对齐：RLHF 先训练奖励模型再用强化学习优化；DPO 直接用偏好对优化，省去奖励模型与强化学习，工程更简单，是当前主流替代方案。
- 三者关系：预训练决定“知道什么”，SFT 决定“会不会按要求答”，对齐决定“答得合不合人类偏好与安全规范”。
- 数据质量比数量更重要，去重、清洗、配比直接影响效果；持续训练要警惕灾难性遗忘，即学新任务时旧能力退化。

4. 参数高效微调（案例选型常考）

- 全量微调：更新全部参数，效果上限最高，但显存与算力开销大，每个任务要存一份权重。
- LoRA：冻结基座，旁路注入低秩矩阵（ΔW = BA），只训练两个小矩阵，显存低、可插拔、多任务切换只需换适配器。
- QLoRA：基座先做 4bit 量化再挂 LoRA，进一步压低显存门槛，适合单卡与私有化场景。
- 适配器与提示学习（Prompt/Prefix Tuning）：前者插入小模块，后者只调连续提示向量，同属参数高效路线。
- 选型判据：数据量小、任务多、算力紧优先 LoRA；需要深度改变领域表达且数据充足，才考虑全量微调。

5. 推理过程与解码策略

- 自回归生成：每步输出一个 token 并回填上下文，逐 token 串行，因此时延天然高于传统接口调用。
- 两阶段：预填充（prefill，一次性算完输入，决定首 token 时延 TTFT）与解码（decode，逐 token 生成，决定每 token 时延 TPOT）。二者瓶颈不同、优化手段不同，是性能分析题的落点。
- 解码策略：贪心（确定性强、易重复）、束搜索（质量好但开销成倍）、温度采样（温度低更确定、高更发散）、top-k 与 top-p 核采样（截断长尾、降低胡言）、重复惩罚。
- 结构化输出：约束解码或函数调用 schema，保证返回可被程序稳定解析。
- 关键指标：TTFT、TPOT、吞吐（tokens/s）、并发数、单位任务成本，五者互相牵制，扩容不能只加副本。

6. 推理加速与部署优化

- KV 缓存：缓存历史 token 的 Key/Value，避免每步重算；显存占用随上下文线性增长，是并发能力的主要瓶颈。
- PagedAttention 与连续批处理：把 KV 缓存分页管理、动态拼批，显著提升显存利用率与吞吐，这是 vLLM 一类推理框架的核心机制。
- 量化：权重 INT8/INT4（W8A16、W4A16），以少量精度换显存与速度；KV 缓存量化可进一步降显存。
- 蒸馏与剪枝：小模型学习大模型的输出分布，或去掉冗余结构，用于端侧与低成本场景。
- MoE 混合专家：稀疏激活，总参数大而单次计算只走部分专家，兼顾能力与成本。

- 并行策略：张量并行（层内切分）、流水并行（层间切分）、数据并行（多副本），大模型推理常组合使用。

7. 向量化与语义检索（RAG 的地基）

- 嵌入：把文本映射为稠密向量，语义相近则向量距离近；相似度常用余弦相似度或内积。
- 与传统检索的分工：BM25 与倒排索引擅长关键词精确匹配，向量检索擅长同义改写与语义泛化，双路召回再加融合的混合检索最稳。
- 近似最近邻索引：HNSW 为图索引，召回高但内存占用大；IVF 为聚类倒排，速度快但需调探测数；PQ 做乘积量化，压缩向量但损失精度。
- 向量数据库选型指标：维度与数据规模、召回率与 QPS、元数据过滤能力、是否支持混合检索、水平扩展与运维成本。代表产品有 Milvus、Qdrant、Chroma、PGVector、Elasticsearch。
- 分块策略：按语义边界切分、保留重叠窗口防语义被切断、采用父子块（小块检索、大块喂给模型）。

8. RAG 流程与效果评估（与第23章互补）

- 七步主线：加载 → 分块 → 向量化 → 入库 → 召回 → 重排 → 组装提示并生成、附引用出处。
- 两段检索：粗召回保证覆盖率，重排（交叉编码器）保证精度，二者分工是准确率关键。
- 生成约束：要求只依据召回内容作答、标注来源、无依据时明确拒答。
- 评估指标：召回率与命中率衡量检索环节，忠实度衡量是否忠于材料，答案相关性衡量是否答到点上；离线跑评测集，线上看人工反馈与差评归因。
- 常见失效：知识未入库、分块切碎语义、召回不足、缺少重排、提示过长挤掉关键信息。

9. 提示工程与提示注入

- 基本范式：零样本、少样本（给示例定格式）、思维链（要求分步推理）、角色与约束设定。
- 结构化提示：按“输入、任务、约束、输出格式”四段组织，比长篇自然语言更稳定。
- 提示注入：用户输入夹带“忽略以上指令”一类内容劫持模型行为，属输入侧安全风险；防护靠指令与数据分隔、输入过滤、权限最小化、工具调用白名单。
- 越狱：诱导模型绕过安全策略；防护靠系统提示加固、输出审核、红队测试。
- 边界：提示工程解决“怎么问”，不能替代知识更新（RAG）与能力改变（微调）。

10. 幻觉、评测与模型选型

- 幻觉两类：事实性幻觉（与客观事实不符）、忠实性幻觉（与给定材料矛盾）。
- 成因：模型按概率续写而非查证、训练数据噪声、长上下文中间信息丢失、提示缺乏约束。
- 抑制：RAG 加引用溯源、降低温度、明确要求“不知道就说不知道”、关键结论人工复核、输出结构化校验。
- 评测方法：构建业务评测集做回归测试；客观题看准确率，生成题看忠实度与人工评分；LLM-as-judge 可规模化但有偏差，需抽样人工校准。
- 选型维度：能力（推理、代码、多模态）、上下文长度、时延与吞吐、单价与私有化可行性、微调与工具调用支持、数据合规。闭源 API 上线快、能力强但数据出域；开源私有化数据可控、可微调，但需自建算力与运维。

11. LLM 与传统技术结合（案例落点）

- LLM 与数据库：Text2SQL 把自然语言转成 SQL，难点在库表 Schema 链接、歧义消解与结果校验；工程上用 Schema 裁剪、少样本示例、执行报错自纠正、只读账号与行级权限兜底。
- LLM 与检索：RAG 是最常见的落地形态，见本节第8条。
- LLM 与规则、工作流：确定性环节仍用规则与状态机，LLM 只承担语义理解与生成，避免全链路不可控。
- LLM 与智能体：LLM 提供推理，智能体提供规划、工具与记忆，完整架构见第23章。
- 与传统机器学习的分工：分类、回归、推荐等判别式任务，小模型成本低、可解释、输出稳定；LLM 适合非结构化理解、生成与跨任务泛化，不能用它一刀切替代。

12. 易混概念辨析（选择题高频）

概念对	判据（一句话区分）
预训练 vs 微调	学语言与世界知识 vs 学任务与输出格式
SFT vs RLHF/DPO	监督学“怎么答” vs 用偏好学“哪种答更好”
LoRA vs 全量微调	只训低秩旁路、可插拔 vs 更新全部参数、成本高
RAG vs 微调	外挂知识、可溯源可更新 vs 改权重、成本高且难溯源
提示工程 vs RAG	怎么问 vs 喂什么
向量检索 vs 关键词检索	语义泛化 vs 精确匹配，混合检索最优
温度 vs top-p	调概率分布平滑度 vs 截断候选集范围
KV 缓存 vs 缓存中间件	推理内部张量复用 vs 业务数据缓存
LLM vs 智能体	推理内核 vs 含规划、工具、记忆的工程系统

13. 安全与合规底线

- 数据：训练与推理数据不出域、脱敏、租户隔离，敏感行业优先私有化部署或专有实例。
- 内容：生成内容审核与标识，敏感话题配置拒答策略。
- 权限：模型不直接持有数据库凭证，统一经工具网关以最小权限访问，调用日志留痕可审计。
- 供应链：核查模型来源与许可证、依赖组件漏洞，密钥集中管理。

三、备考建议

综合知识以概念辨析为主，优先掌握四组对比（预训练与微调、SFT 与对齐、RAG 与微调、向量检索与关键词检索），再记 Transformer 自注意力与位置编码、上下文窗口、KV 缓存、两级时延指标这几个可出计算题或“属于/不属于”判断题的点。

案例分析按三条线准备：性能线（TTFT、TPOT、吞吐与并发，对应 KV 缓存、PagedAttention、量化与并行）、知识线（分块、召回、重排、引用溯源与幻觉抑制）、成本线（token 计费、缓存命中、模型分级路由）。答题要落到具体机制名，避免只写“优化性能”。

论文方面，2026 年上半年已考 LLM 辅助测试，后续大概率继续围绕大模型在需求、设计、测试、运维中的落地命题，建议按“业务痛点、技术方案、实施过程、效果数据、不足改进”五段准备，并与第23章智能体素材共用案例背景。复习时抓机制与选型判据即可，不必记参数规模与榜单排名。